Projet : Analyse de données financières

1. Jeu de données et objectif

On travaille sur les données quotidiennes du **Dow Jones Industrial Average (DJIA)**, indice regroupant 30 grandes entreprises américaines, de janvier 2015 à décembre 2025. Chaque ligne correspond à une séance boursière et contient : **Date**, **Open**, **High**, **Low**, **Close** et **Volume** .

- Date : date de la séance boursière.
- Open : valeur de l'indice à l'ouverture de la séance.
- High : valeur maximale atteinte durant la séance.
- Low : valeur minimale atteinte durant la séance.
- Close : valeur de l'indice à la clôture de la séance.
- Volume : volume des transactions associé à la série de marché.

Objectif : appliquer des méthodes d'optimisation à des données réelles :

- I. une régression linéaire pour prédire le rendement financier du lendemain
- II. un SVM pour construire un hyperplan affine permettant de séparer deux classes correspondant à la hausse et à la baisse du marché

2. Préparation des données

NB : Dans ce projet, nous utiliserons uniquement la colonne `Close` du fichier de données fourni, correspondant aux prix de clôture quotidiens de l'indice Dow Jones.

Trier les données par date croissante et calculer, pour $t = 2, \dots, T-1$ ($n = T-2$ observations utilisables) :

$$R_t = \ln\left(\frac{\text{Close}_t}{\text{Close}_{t-1}}\right), \qquad y_t = R_{t+1}, \qquad x_{1,t} = R_t, \qquad x_{2,t} = \frac{\text{High}_t - \text{Low}_t}{\text{Close}_t}.$$

Découper les données **chronologiquement** : 80 % premières observations pour l'entraînement, 20 % dernières pour le test (pas de mélange aléatoire). Tous les paramètres sont estimés sur l'entraînement uniquement.

Partie I : Régression linéaire et optimisation

Notre objectif est de construire un modèle de régression linéaire capable de prédire le rendement financier du lendemain. Pour cela, nous devons déterminer les coefficients du modèle. Nous cherchons donc les coefficients qui minimisent l'écart entre les rendements réels et les rendements prédits. Pour mesurer cet écart, nous utilisons la somme des carrés des erreurs, appelée somme des erreurs quadratiques.

Modèle : $\widehat{y}_t = \beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t}$. On résout

$$\min_{\beta \in \mathbb{R}^3} J(\beta) = \frac{1}{2n} \|X\beta - y\|_2^2 ,$$

où $X \in \mathbb{R}^{n \times 3}$ (première colonne de 1, puis x_1 et x_2), $y \in \mathbb{R}^n$ et $\beta = (\beta_0, \beta_1, \beta_2)^T$.

Travail demandé :

1. Construire X et y (donner leurs dimensions).
2. Développer $J(\beta)$, puis calculer son gradient $\nabla J(\beta)$ et sa hessienne $\nabla^2 J(\beta)$. Montrer que J est convexe.
3. Écrire la condition d'optimalité $\nabla J(\widehat{\beta}) = 0$ et en déduire l'équation normale $X^T X \widehat{\beta} = X^T y$.
4. Calculer $\widehat{\beta}$ en résolvant l'équation normale.
5. Utiliser Python pour déterminer les coefficients optimaux du modèle de régression linéaire
   Comparer les résultats obtenus avec ceux calculés par la méthode de l'équation normale dans la question précédente.

6. Calculer les rendements prédits, le **MSE** et le coefficient de détermination R^2, sur l'entraînement et sur le test. Comparer avec le modèle qui prédit toujours la moyenne de y.
7. Interpréter les résultats (signe des coefficients, valeur de R^2, limites du modèle). *Un R^2 proche de 0 est attendu pour des rendements journaliers.*

Partie II : Support Vector Machine (SVM)

On définit l'étiquette $z_t = +1$ si $R_{t+1} > 0$ (hausse) et $z_t = -1$ si $R_{t+1} \leq 0$ (baisse). On garde les variables $x_{1,t}$ et $x_{2,t}$ de la partie I, que l'on **standardise** (moyenne et écart-type calculés sur l'entraînement).

On cherche un hyperplan affine $w_1 x_1 + w_2 x_2 + b = 0$ en résolvant

$$\min_{w,b,\xi} \ \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{n} \xi_i \quad \text{sous} \quad z_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

Travail demandé :

1. Construire les deux classes (hausse et baisse) et les représenter dans le plan (x_1, x_2) avec deux couleurs différentes.
2. Construire l'hyperplan affine (par exemple avec `sklearn.svm.SVC(kernel='linear')`) et identifier ses paramètres w_1, w_2 et b.
3. Représenter graphiquement l'hyperplan et les deux régions de classification. Interpréter la séparation obtenue et discuter les éventuelles erreurs de classification.

Consignes générales et modalités de rendu

— Le travail demandé est un travail **individuel**.
— L'utilisation de **Python** est fortement recommandée pour effectuer les calculs numériques et réaliser les représentations graphiques.
— Le compte rendu doit présenter les développements mathématiques, les résultats numériques obtenus ainsi que leur interprétation et leur analyse.
— Les graphiques doivent être lisibles et comporter un titre, des axes correctement identifiés et une légende.

Document à rendre :

Un **rapport au format PDF** présentant :

— Les développements et les justifications mathématiques.
— Les résultats pratiques obtenus.
— Les tableaux et les représentations graphiques nécessaires.
— L'interprétation et la discussion des résultats.

Remarque : Le code Python n'est pas demandé. Seuls les résultats obtenus, accompagnés de leurs explications et interprétations, doivent figurer dans le rapport.

Données : Le fichier de données financières est fourni avec le présent énoncé.

Bon travail !