Analyse de données financières

Régression linéaire et machine à vecteurs de support (SVM)
appliquées au Dow Jones Industrial Average (2015–2025)

Salem Essid
INDP2C

Code source : `https://github.com/SalemEssid/Optimization_project.git`

Projet d'optimisation – INDP2

Novembre 2026

Résumé

À partir des cours quotidiens du Dow Jones (2 766 séances), on construit $n = 2\,764$ observations (2 211 pour l'entraînement, 553 pour le test, découpage chronologique). La régression du rendement du lendemain sur le rendement du jour et l'amplitude relative de la séance donne $\hat{\beta} = (8{,}18 \cdot 10^{-4}\,;\, -0{,}156\,;\, -0{,}0417)$. Ces coefficients sont obtenus par l'équation normale et retrouvés, à moins de $2 \cdot 10^{-11}$ près, par six méthodes numériques. Le coefficient de détermination vaut 2,35 % sur l'entraînement et $-3{,}69$ % sur le test : hors échantillon, le modèle ne fait pas mieux que la simple moyenne.

Le SVM linéaire ($C = 1$) aboutit à $w \approx 0$ et $b \approx 1$: il prédit « hausse » tous les jours. Nous montrons que c'est l'optimum exact du problème, conséquence de l'imbrication complète des deux classes.

Les deux approches concluent que le rendement journalier est presque imprévisible à partir de ces deux variables. Comme travail futur, nous proposons d'utiliser l'astuce du noyau pour chercher une frontière non linéaire, avec un protocole de validation adapté aux séries temporelles.

Sommaire

1 Jeu de données et préparation **4**
1.1 Le fichier de données 4
1.2 Variables du modèle 4
1.3 Découpage chronologique 5

2 Partie I : régression linéaire et optimisation **7**
2.1 Construction de X et y 7
2.2 Développement de J, gradient, hessienne et convexité 7
2.3 Condition d'optimalité et équation normale 8
2.4 Calcul de $\hat{\beta}$ par l'équation normale 8
2.5 Résolution numérique avec Python et comparaison 10
2.6 Prédictions, MSE et coefficient de détermination 10
2.7 Interprétation et limites 11

3 Partie II : machine à vecteurs de support (SVM) **14**
3.1 Formulation et rappels théoriques 14
3.2 Construction et représentation des deux classes 14
3.3 Hyperplan obtenu avec `SVC(kernel='linear')` 15
3.4 Représentation graphique, régions de classification et erreurs 16

4 Travaux futurs : l'astuce du noyau **18**
4.1 Principe 19
4.2 Protocole prévu 19

5 Conclusion **20**

1 Jeu de données et préparation

1.1 Le fichier de données

Le fichier *Dow Jones Industrial.csv* contient 2 768 lignes, du 02/01/2015 au 31/12/2025, avec les colonnes *Date*, *Price*, *Open*, *High*, *Low*, *Vol.* et *Change %*. Conformément à la remarque de l'énoncé, **la colonne *Price* correspond au cours de clôture *Close*** : elle est renommée *Close* et c'est elle qui sert au calcul des rendements. Les colonnes *High* et *Low* n'interviennent que dans la variable $x_{2,t}$ imposée par l'énoncé.

La préparation comporte trois étapes :

- **Conversion** : les dates sont au format mois/jour/année et les prix contiennent un séparateur de milliers (« 48,063.29 ») ; ils sont convertis en dates et en nombres réels.
- **Tri par date croissante** : le fichier est fourni du plus récent au plus ancien.
- **Suppression de deux lignes qui ne sont pas des séances** : le 25/12/2024 et le 25/12/2025. Le marché américain est fermé le jour de Noël ; ces lignes recopient la clôture de la veille (variation de 0,00 %, volume absent en 2024, High = Low = Close en 2025) et créeraient un rendement nul artificiel. Il reste $T = 2\,766$ séances, ce qui correspond exactement au calendrier du NYSE (2015 : 252, 2016 : 252, 2017 : 251, 2018 : 251, 2019 : 252, 2020 : 253, 2021 : 252, 2022 : 251, 2023 : 250, 2024 : 252, 2025 : 250). Si l'on conserve ces deux lignes, les coefficients de la partie I varient d'au plus $2 \cdot 10^{-4}$ et les R^2 deviennent 2,35 % et −3,71 % : les conclusions sont inchangées.

Sur la période, l'indice passe de 17 833 à 48 063 points (+170 %). Son minimum (15 660) est atteint le 11/02/2016 et son maximum (48 731) le 24/12/2025 (figure 1).

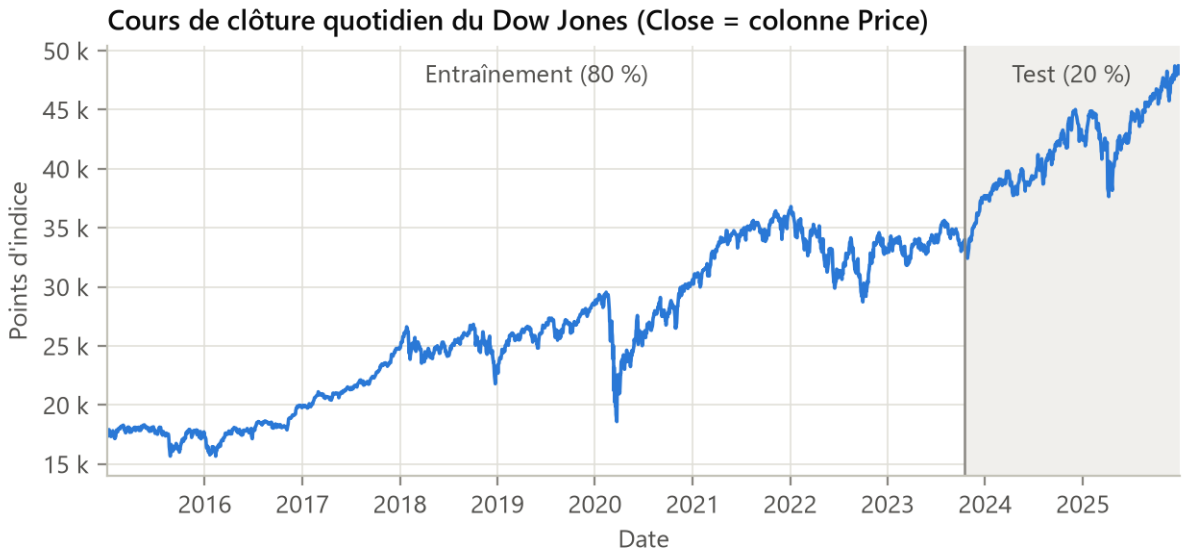


Figure 1 – Cours de clôture quotidien du Dow Jones (colonne *Price*). La zone grisée correspond à la période de test (20 % finaux).

1.2 Variables du modèle

Pour $t = 2, \ldots, T-1$, on définit :

$$R_t = \ln\left(\frac{\text{Close}_t}{\text{Close}_{t-1}}\right), \qquad y_t = R_{t+1}, \qquad x_{1,t} = R_t, \qquad x_{2,t} = \frac{\text{High}_t - \text{Low}_t}{\text{Close}_t}.$$

R_t est le **rendement logarithmique** de la séance t et $x_{2,t}$ l'**amplitude relative** de la séance, une mesure simple de la volatilité intrajournalière. La cible y_t est le rendement du lendemain.

Les deux variables explicatives sont connues à la clôture de la séance t et la cible ne l'est qu'à la clôture de $t+1$: le modèle n'utilise aucune information future. R_1 n'est pas défini (il faudrait Close_0) et $y_T = R_{T+1}$ non plus, d'où $n = T - 2 = 2\,764$ observations utilisables.

Tableau 1 – Statistiques descriptives sur l'entraînement (2 211 observations) et sur le test (553 observations). La kurtosis en excès vaut 0 pour une loi normale.

	Entraînement			Test		
	$x_{1,t}$	$x_{2,t}$	y_t	$x_{1,t}$	$x_{2,t}$	y_t
Moyenne	0,029 %	1,133 %	0,030 %	0,064 %	1,011 %	0,063 %
Écart-type	1,153 %	0,853 %	1,153 %	0,877 %	0,678 %	0,878 %
Minimum	−13,84 %	0,17 %	−13,84 %	−5,66 %	0,23 %	−5,66 %
Maximum	10,76 %	8,21 %	10,76 %	7,58 %	8,63 %	7,58 %
Asymétrie	−0,95	3,05	−0,95	0,38	5,33	0,38
Kurtosis (excès)	21,9	15,5	21,9	13,5	45,3	13,5

Les rendements journaliers ont une moyenne très faible devant leur dispersion (0,029 % contre 1,15 % sur l'entraînement, tableau 1). Leur distribution a une asymétrie négative (−0,95) et des queues très épaisses (kurtosis en excès 21,9). Les extrêmes datent de la crise du Covid-19 : −13,8 % le 16/03/2020 et +10,8 % le 24/03/2020. L'amplitude maximale (8,6 %) est observée le 09/04/2025, pendant l'épisode des droits de douane. La figure 2 montre le regroupement de la volatilité : les fortes variations arrivent par vagues, et $x_{2,t}$ suit ces vagues. Sur l'entraînement, $\text{corr}(x_1, x_2) = -0{,}181$, $\text{corr}(y, x_1) = -0{,}150$ et $\text{corr}(y, x_2) = -0{,}0026$.

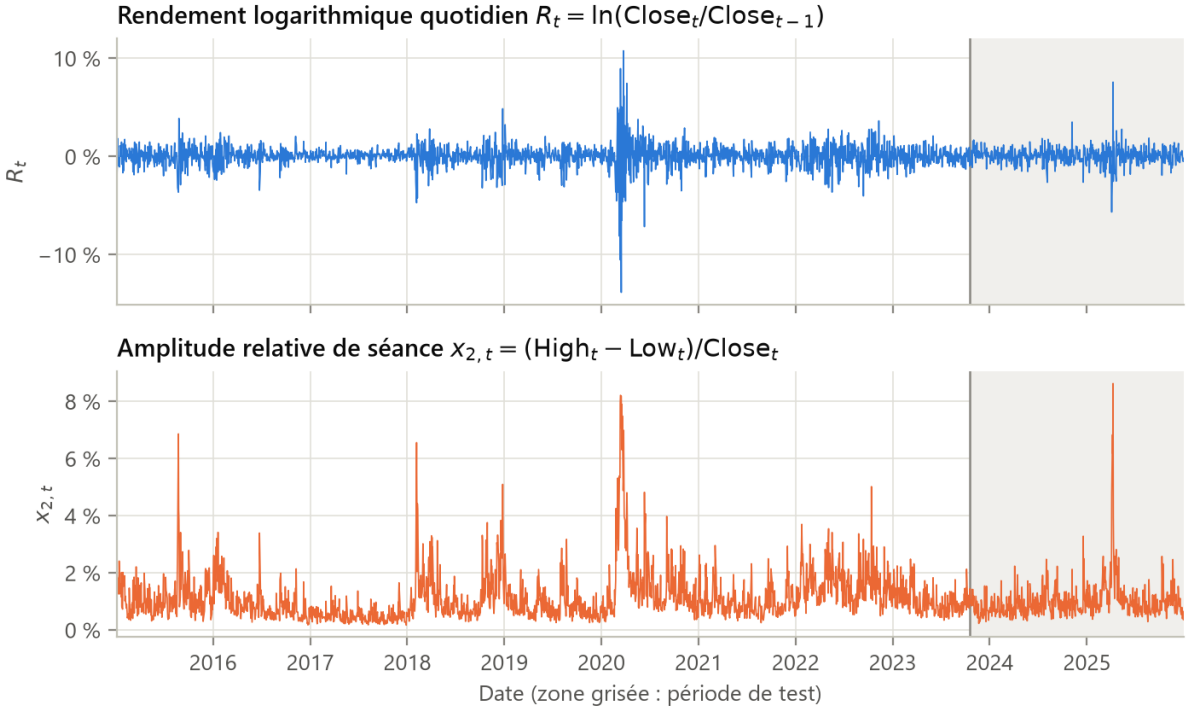


Figure 2 – Rendement logarithmique R_t (en haut) et amplitude relative $x_{2,t}$ (en bas). Les pics coïncident : la volatilité se regroupe par épisodes (2015-2016, 2018, mars 2020, 2022, avril 2025).

1.3 Découpage chronologique

Les observations sont découpées **sans mélange aléatoire** : les $n_{\text{train}} = \lfloor 0{,}8\,n \rfloor = 2\,211$ premières (séances t du 05/01/2015 au 16/10/2023) forment l'ensemble d'entraînement et les

$n_{\text{test}} = 553$ dernières (du 17/10/2023 au 30/12/2025, la dernière cible étant le rendement du 31/12/2025) l'ensemble de test. Tous les paramètres (coefficients, moyennes, écarts-types de standardisation, hyperplan) sont estimés sur l'entraînement uniquement. Les deux périodes diffèrent : l'entraînement contient le krach de 2020, alors que la période de test est plus calme (écart-type 0,88 % contre 1,15 %) et plus haussière (55,2 % de séances en hausse contre 53,7 %).

2 Partie I : régression linéaire et optimisation

2.1 Construction de X et y

Le modèle est $\hat{y}_t = \beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t}$, de paramètre $\beta = (\beta_0, \beta_1, \beta_2)^T \in \mathbb{R}^3$. On empile les observations :

$$X = \begin{pmatrix} 1 & x_{1,2} & x_{2,2} \\ 1 & x_{1,3} & x_{2,3} \\ \vdots & \vdots & \vdots \\ 1 & x_{1,T-1} & x_{2,T-1} \end{pmatrix} \in \mathbb{R}^{n \times 3}, \qquad y = \begin{pmatrix} y_2 \\ y_3 \\ \vdots \\ y_{T-1} \end{pmatrix} = \begin{pmatrix} R_3 \\ R_4 \\ \vdots \\ R_T \end{pmatrix} \in \mathbb{R}^n.$$

Dimensions
$X \in \mathbb{R}^{2\,764 \times 3}$ et $y \in \mathbb{R}^{2\,764}$ au total ; après découpage, $X_{\text{train}} \in \mathbb{R}^{2\,211 \times 3}$, $y_{\text{train}} \in \mathbb{R}^{2\,211}$, $X_{\text{test}} \in \mathbb{R}^{553 \times 3}$, $y_{\text{test}} \in \mathbb{R}^{553}$. Dans la suite, X, y et n désignent l'ensemble d'entraînement ($n = 2\,211$).

Le tableau 2 donne les premières lignes de X et y, ainsi que les dernières lignes de l'entraînement et du test.

Tableau 2 – Extrait de X et y (chaque ligne de X est $(1,\, x_{1,t},\, x_{2,t})$).

Ligne	Séance t	1	$x_{1,t}$	$x_{2,t}$	y_t	Ensemble
$t = 2$	05/01/2015	1	−0,018755	0,019734	−0,007456	entraînement
$t = 3$	06/01/2015	1	−0,007456	0,018345	0,012180	entraînement
$t = 4$	07/01/2015	1	0,012180	0,012642	0,018221	entraînement
$t = 2\,212$	16/10/2023	1	0,009290	0,007549	0,000386	entraînement (dernière)
$t = 2\,765$	30/12/2025	1	−0,001960	0,003607	−0,006300	test (dernière)

2.2 Développement de J, gradient, hessienne et convexité

La fonction de coût est

$$J(\beta) = \frac{1}{2n}\|X\beta - y\|_2^2 = \frac{1}{2n}\sum_t \left(\beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t} - y_t\right)^2.$$

Développement. En écrivant $\|v\|_2^2 = v^T v$ et en utilisant $y^T X\beta = (y^T X\beta)^T = \beta^T X^T y$ (c'est un scalaire) :

$$J(\beta) = \frac{1}{2n}(X\beta - y)^T(X\beta - y) = \frac{1}{2n}\Big(\beta^T X^T X\beta - 2\,\beta^T X^T y + y^T y\Big). \tag{1}$$

J est donc une forme quadratique en β, de matrice $\frac{1}{2n}X^T X$, à laquelle s'ajoutent un terme linéaire et une constante.

Gradient. Pour une matrice symétrique A, $\nabla_\beta(\beta^T A\beta) = 2A\beta$, et $\nabla_\beta(\beta^T c) = c$. Avec $A = X^T X$ (symétrique) et $c = X^T y$:

$$\nabla J(\beta) = \frac{1}{n}(X^T X\beta - X^T y) = \frac{1}{n}X^T(X\beta - y), \qquad \frac{\partial J}{\partial \beta_j} = \frac{1}{n}\sum_t (\hat{y}_t - y_t)\, X_{tj}. \tag{2}$$

Composante par composante, $\partial J/\partial\beta_0$ est la moyenne des erreurs $\hat{y}_t - y_t$, et $\partial J/\partial\beta_1$ (resp. $\partial J/\partial\beta_2$) leur moyenne pondérée par $x_{1,t}$ (resp. $x_{2,t}$).

Hessienne. En dérivant encore une fois :

$$\nabla^2 J(\beta) = \frac{1}{n} X^T X = \frac{1}{n} \begin{pmatrix} n & \sum x_{1,t} & \sum x_{2,t} \\ \sum x_{1,t} & \sum x_{1,t}^2 & \sum x_{1,t}x_{2,t} \\ \sum x_{2,t} & \sum x_{1,t}x_{2,t} & \sum x_{2,t}^2 \end{pmatrix}. \tag{3}$$

Elle ne dépend pas de β, et le développement de Taylor à l'ordre 2 est exact : $J(\beta + h) = J(\beta) + \nabla J(\beta)^T h + \frac{1}{2} h^T \nabla^2 J\, h$ pour tous $\beta, h \in \mathbb{R}^3$.

Convexité. Pour tout $v \in \mathbb{R}^3$,

$$v^T \nabla^2 J\, v = \frac{1}{n}\, v^T X^T X v = \frac{1}{n} \|Xv\|_2^2 \ \geq 0.$$

La hessienne est donc semi-définie positive en tout point, et J, de classe C^2, est **convexe**. De plus, si les colonnes de X sont linéairement indépendantes ($\operatorname{rang} X = 3$), alors $Xv = 0 \Rightarrow v = 0$: la hessienne est définie positive et J est **strictement** (et même fortement) convexe. C'est le cas ici : sur l'entraînement,

$$\nabla^2 J = \begin{pmatrix} 1 & 2{,}917 \cdot 10^{-4} & 0{,}01133 \\ 2{,}917 \cdot 10^{-4} & 1{,}330 \cdot 10^{-4} & -1{,}454 \cdot 10^{-5} \\ 0{,}01133 & -1{,}454 \cdot 10^{-5} & 2{,}012 \cdot 10^{-4} \end{pmatrix},$$

dont les valeurs propres sont

$$\lambda_1 = 6{,}79 \cdot 10^{-5}, \qquad \lambda_2 = 1{,}38 \cdot 10^{-4}, \qquad \lambda_3 = 1{,}0001.$$

Les trois valeurs propres sont strictement positives : J est μ-fortement convexe avec $\mu = \lambda_{\min} = 6{,}79 \cdot 10^{-5}$, et son gradient est L-lipschitzien avec $L = \lambda_{\max} = 1{,}0001$. Le conditionnement $\kappa = L/\mu \approx 1{,}47 \cdot 10^4$ est élevé, car la colonne de 1 est d'ordre 1 alors que x_1 et x_2 sont d'ordre 10^{-2}. Ce point compte pour les méthodes itératives (section 2.5).

2.3 Condition d'optimalité et équation normale

Le problème $\min_{\beta \in \mathbb{R}^3} J(\beta)$ est sans contrainte, et J est convexe et différentiable. La condition du premier ordre est donc **nécessaire et suffisante** :

$$\hat{\beta} \text{ minimise } J \iff \nabla J(\hat{\beta}) = 0.$$

Elle est nécessaire par la règle de Fermat (minimum sur un ouvert). Elle est suffisante grâce au développement exact : si $\nabla J(\hat{\beta}) = 0$, alors $J(\hat{\beta} + h) = J(\hat{\beta}) + \frac{1}{2} h^T \nabla^2 J\, h \geq J(\hat{\beta})$ pour tout h. Si la hessienne est définie positive, l'inégalité est stricte pour $h \neq 0$: le minimiseur est **unique**. Avec (2) :

$$\nabla J(\hat{\beta}) = \frac{1}{n} X^T (X\hat{\beta} - y) = 0 \iff \boxed{X^T X\, \hat{\beta} = X^T y} \qquad \text{(équation normale)}. \tag{4}$$

Comme $X^T X$ est inversible, $\hat{\beta} = (X^T X)^{-1} X^T y$. L'équation (4) s'écrit aussi $X^T \hat{e} = 0$, avec $\hat{e} = y - X\hat{\beta}$: le vecteur des résidus est orthogonal à chaque colonne de X ($\sum_t \hat{e}_t = 0$, $\sum_t \hat{e}_t x_{1,t} = 0$, $\sum_t \hat{e}_t x_{2,t} = 0$). Autrement dit, $X\hat{\beta}$ est la projection orthogonale de y sur le sous-espace engendré par les colonnes de X.

2.4 Calcul de $\hat{\beta}$ par l'équation normale

Sur l'entraînement, les sommes intervenant dans (4) valent :

$$X^T X = \begin{pmatrix} 2\,211 & 0{,}64486 & 25{,}054 \\ 0{,}64486 & 0{,}29413 & -0{,}032150 \\ 25{,}054 & -0{,}032150 & 0{,}44485 \end{pmatrix}, \qquad X^T y = \begin{pmatrix} 0{,}66400 \\ -0{,}043937 \\ 0{,}0069563 \end{pmatrix}.$$

Élimination de la constante. La première équation de (4), divisée par n, donne $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}_1 - \hat{\beta}_2\bar{x}_2$, avec $\bar{x}_1 = 2{,}917 \cdot 10^{-4}$, $\bar{x}_2 = 0{,}01133$ et $\bar{y} = 3{,}003 \cdot 10^{-4}$. En reportant dans les deux autres équations, on obtient un système 2×2 en variables centrées, qui fait intervenir les covariances empiriques $S_{jk} = \frac{1}{n}\sum_t (x_{j,t} - \bar{x}_j)(x_{k,t} - \bar{x}_k)$ et $S_{jy} = \frac{1}{n}\sum_t (x_{j,t} - \bar{x}_j)(y_t - \bar{y})$:

$$\begin{pmatrix} S_{11} & S_{12} \\ S_{12} & S_{22} \end{pmatrix} \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} S_{1y} \\ S_{2y} \end{pmatrix},$$

soit numériquement

$$\begin{pmatrix} 1{,}3294 \cdot 10^{-4} & -1{,}7846 \cdot 10^{-5} \\ -1{,}7846 \cdot 10^{-5} & 7{,}2797 \cdot 10^{-5} \end{pmatrix} \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} -1{,}9959 \cdot 10^{-5} \\ -2{,}5678 \cdot 10^{-7} \end{pmatrix}.$$

Résolution (règle de Cramer). Le déterminant vaut $\Delta = S_{11}S_{22} - S_{12}^2 = 9{,}3594 \cdot 10^{-9} > 0$, puis

$$\begin{aligned} \hat{\beta}_1 &= \frac{S_{1y}S_{22} - S_{12}S_{2y}}{\Delta} = \frac{-1{,}4576 \cdot 10^{-9}}{9{,}3594 \cdot 10^{-9}} = -0{,}15573, \\ \hat{\beta}_2 &= \frac{S_{11}S_{2y} - S_{12}S_{1y}}{\Delta} = \frac{-3{,}9033 \cdot 10^{-10}}{9{,}3594 \cdot 10^{-9}} = -0{,}041705, \\ \hat{\beta}_0 &= \bar{y} - \hat{\beta}_1\bar{x}_1 - \hat{\beta}_2\bar{x}_2 = 8{,}1831 \cdot 10^{-4}. \end{aligned}$$

Modèle estimé

$$\hat{y}_t = 8{,}1831 \cdot 10^{-4} - 0{,}15573\, x_{1,t} - 0{,}041705\, x_{2,t}.$$

Au point $\hat{\beta}$, $\|\nabla J(\hat{\beta})\| = 1{,}7 \cdot 10^{-20}$ (zéro à la précision machine) et $J(\hat{\beta}) = 6{,}4831 \cdot 10^{-5}$, contre $J(0) = 6{,}6435 \cdot 10^{-5}$: le coût baisse de seulement 2,42 %.

La figure 3 montre la cible en fonction de chaque variable, avec l'effet partiel estimé (l'autre variable étant fixée à sa moyenne). La pente négative en x_1 est visible mais faible devant la dispersion du nuage. L'effet de x_2 est presque plat.

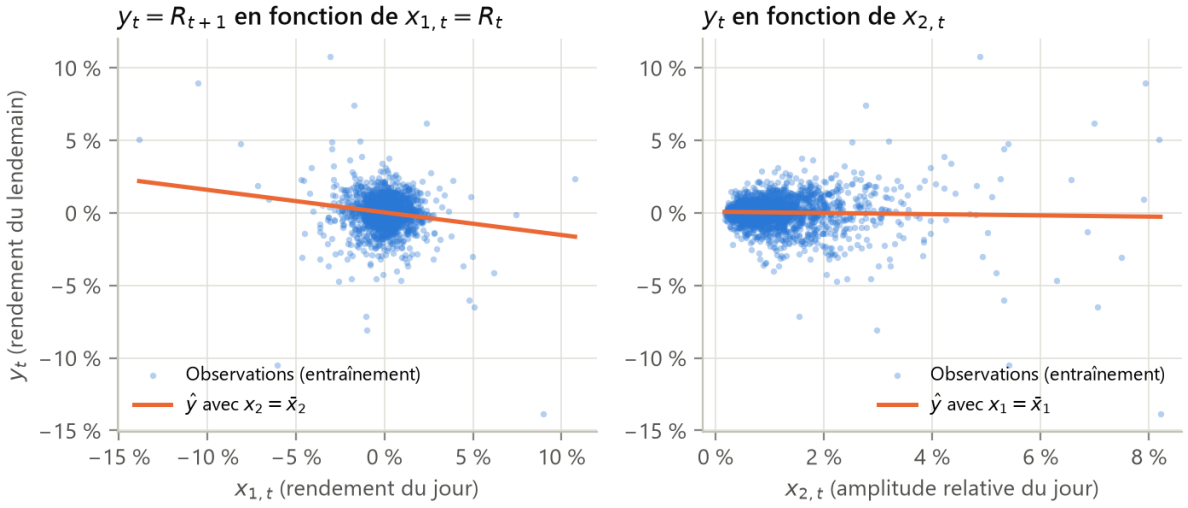


Figure 3 – Rendement du lendemain en fonction de $x_{1,t}$ (à gauche) et de $x_{2,t}$ (à droite), entraînement. Les droites représentent le modèle estimé, l'autre variable étant fixée à sa moyenne.

2.5 Résolution numérique avec Python et comparaison

En plus de la résolution directe du système (4), les coefficients optimaux ont été recalculés de six autres façons. Deux sont directes : `LinearRegression` de scikit-learn et `numpy.linalg.lstsq`, qui résout le problème des moindres carrés par décomposition en valeurs singulières sans former X^TX. Quatre sont itératives et minimisent directement J avec son gradient (2) : BFGS (quasi-Newton), Newton avec la hessienne exacte (3) (ces deux méthodes via `scipy.optimize.minimize`), et la descente de gradient $\beta^{(k+1)} = \beta^{(k)} - \frac{1}{L}\nabla J(\beta^{(k)})$ à pas fixe $1/L$, sur les variables brutes puis sur les variables standardisées (les coefficients sont ensuite ramenés aux unités d'origine). Les itérations partent de $\beta^{(0)} = 0$ et s'arrêtent quand $\|\beta^{(k)} - \hat{\beta}\| \leq 10^{-10}\|\hat{\beta}\|$.

Tableau 3 – Coefficients obtenus par différentes méthodes Python (10 décimales). La dernière colonne donne l'écart maximal à la solution de l'équation normale (EN), $\max_j |\beta_j - \hat{\beta}_j^{\mathrm{EN}}|$.

Méthode	$\hat{\beta}_0$	$\hat{\beta}_1$	$\hat{\beta}_2$	Itérations	Écart à l'EN
Équation normale (résolution directe)	0,0008183112	−0,1557327126	−0,0417048198	–	0
`LinearRegression` (scikit-learn)	0,0008183112	−0,1557327126	−0,0417048198	–	$2 \cdot 10^{-16}$
`numpy.linalg.lstsq` (SVD)	0,0008183112	−0,1557327126	−0,0417048198	–	$2 \cdot 10^{-16}$
BFGS (SciPy)	0,0008183112	−0,1557327126	−0,0417048198	32	$6 \cdot 10^{-12}$
Newton, hessienne exacte (SciPy)	0,0008183112	−0,1557327126	−0,0417048198	1	$3 \cdot 10^{-17}$
Descente de gradient, variables brutes	0,0008183112	−0,1557327126	−0,0417048198	329 123	$2 \cdot 10^{-11}$
Descente de gradient, variables standardisées	0,0008183112	−0,1557327126	−0,0417048198	20	$7 \cdot 10^{-12}$

Comparaison. Toutes les méthodes donnent les mêmes coefficients (tableau 3). Les méthodes directes coïncident avec l'équation normale à la précision machine ($\approx 10^{-16}$) ; les méthodes itératives s'en écartent de moins de $2 \cdot 10^{-11}$, écart fixé par leur critère d'arrêt. C'est attendu : J étant strictement convexe, son minimiseur est unique et toute méthode convergente l'atteint. La méthode de Newton converge en 1 itération, car pour une quadratique le pas de Newton $-(\nabla^2 J)^{-1}\nabla J(\beta^{(0)})$ mène directement à la solution de (4).

Conditionnement et vitesse de la descente de gradient. Avec le pas $1/L$, l'erreur vérifie $\beta^{(k+1)} - \hat{\beta} = (I - \frac{1}{L}\nabla^2 J)(\beta^{(k)} - \hat{\beta})$, dont le facteur de contraction est $1 - \mu/L = 1 - 1/\kappa$. Il faut donc environ $\kappa \ln(10^{10})$ itérations pour gagner dix ordres de grandeur.

- Variables brutes : $\kappa \approx 1{,}47 \cdot 10^4$, soit une prévision d'environ 339 000 itérations ; on en observe 329 123.
- Variables standardisées : la hessienne est proche de l'identité, $\kappa \approx 1{,}44$, le facteur vaut 0,307 et 20 itérations suffisent (prévision $\approx 19{,}5$).

La figure 4 illustre ce comportement. La standardisation ne change pas le modèle, mais elle rend le problème bien conditionné ; c'est aussi pourquoi on standardise les variables dans la partie II.

2.6 Prédictions, MSE et coefficient de détermination

Les rendements prédits sont $\hat{y} = X\hat{\beta}$, sur l'entraînement comme sur le test, avec le même $\hat{\beta}$. Sur un ensemble de m observations, on calcule

$$\mathrm{MSE} = \frac{1}{m}\sum_t (y_t - \hat{y}_t)^2, \qquad R^2 = 1 - \frac{\sum_t (y_t - \hat{y}_t)^2}{\sum_t (y_t - \bar{y})^2},$$

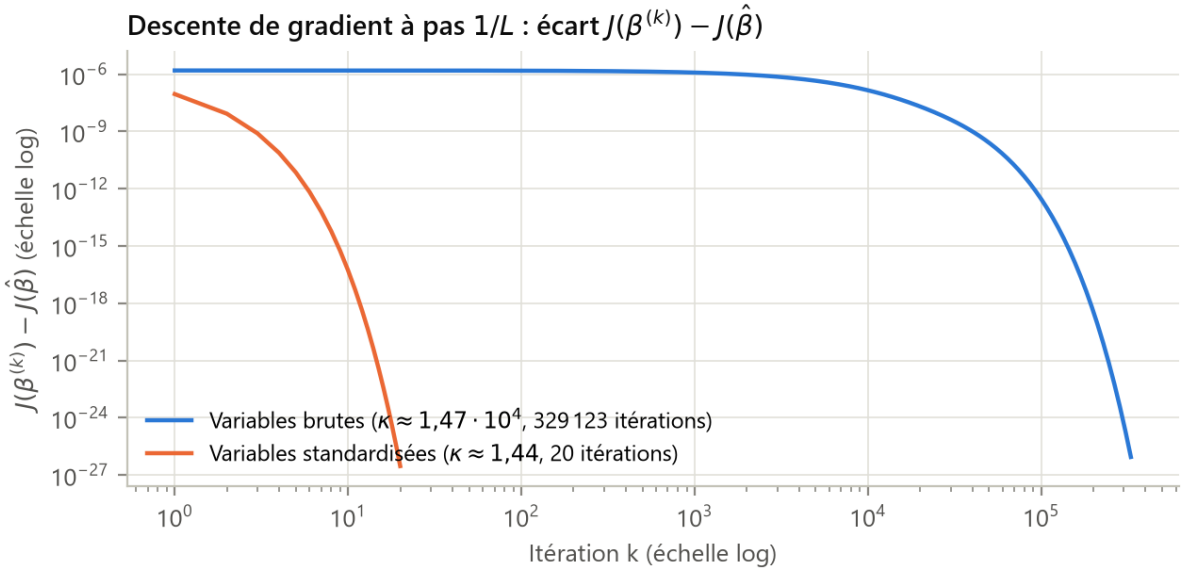


Figure 4 – Convergence de la descente de gradient à pas $1/L$ (axes logarithmiques). Avec les variables brutes ($\kappa \approx 1{,}47 \cdot 10^4$), la décroissance ne démarre qu'après $\sim 10^4$ itérations ; avec les variables standardisées, elle est géométrique dès le départ.

où $\bar{y}$ est la moyenne de l'ensemble évalué. Le modèle de référence prédit toujours la moyenne d'entraînement $\bar{y}_{\text{train}} = 3{,}003 \cdot 10^{-4}$, soit un rendement d'environ 0,030 % par jour.

Tableau 4 – Erreur quadratique moyenne et coefficient de détermination.

	Entraînement		Test	
Modèle	MSE	R^2	MSE	R^2
Régression linéaire	$1{,}2966 \cdot 10^{-4}$	0,0235	$7{,}9749 \cdot 10^{-5}$	−0,0369
Moyenne constante ($\hat{y}_t = \bar{y}_{\text{train}}$)	$1{,}3278 \cdot 10^{-4}$	0	$7{,}7020 \cdot 10^{-5}$	−0,0014

- **Entraînement.** La régression réduit la MSE de 2,35 % par rapport à la moyenne ($R^2 = 0{,}0235$, tableau 4). Le modèle de référence a $R^2 = 0$ par construction, car il prédit exactement la moyenne de l'ensemble évalué. La racine de la MSE (1,139 %) reste presque égale à l'écart-type des rendements (1,152 %).
- **Test.** La régression fait **moins bien** que la moyenne : la MSE augmente de 3,54 % et $R^2 = -0{,}0369$ est négatif. Le modèle constant a lui-même $R^2 = -0{,}0014$ sur le test, parce que la moyenne d'entraînement diffère un peu de la moyenne de test. Calculé par rapport à $\bar{y}_{\text{train}}$, le R^2 hors échantillon vaut $R^2_{\text{OS}} = -3{,}54\,\%$.
- **Amplitude des prédictions.** Les prédictions varient très peu (écart-type 0,18 % contre 1,15 % pour y ; intervalle [−1,81 % ; 1,90 %] sur l'entraînement), comme le montre la figure 5.
- **Sens de variation.** Le signe de $\hat{y}_t$ coïncide avec celui de y_t dans 51,8 % des cas sur l'entraînement et 49,5 % sur le test. Prédire « hausse » tous les jours ferait mieux (53,7 % et 55,2 %).

2.7 Interprétation et limites

Signe des coefficients.

- $\hat{\beta}_0 = 8{,}1831 \cdot 10^{-4} > 0$ traduit la dérive haussière de l'indice. À l'amplitude moyenne ($\bar{x}_2 = 1{,}13\,\%$) et pour un rendement du jour nul, le modèle prévoit $\hat{\beta}_0 + \hat{\beta}_2 \bar{x}_2 = 0{,}035\,\%$

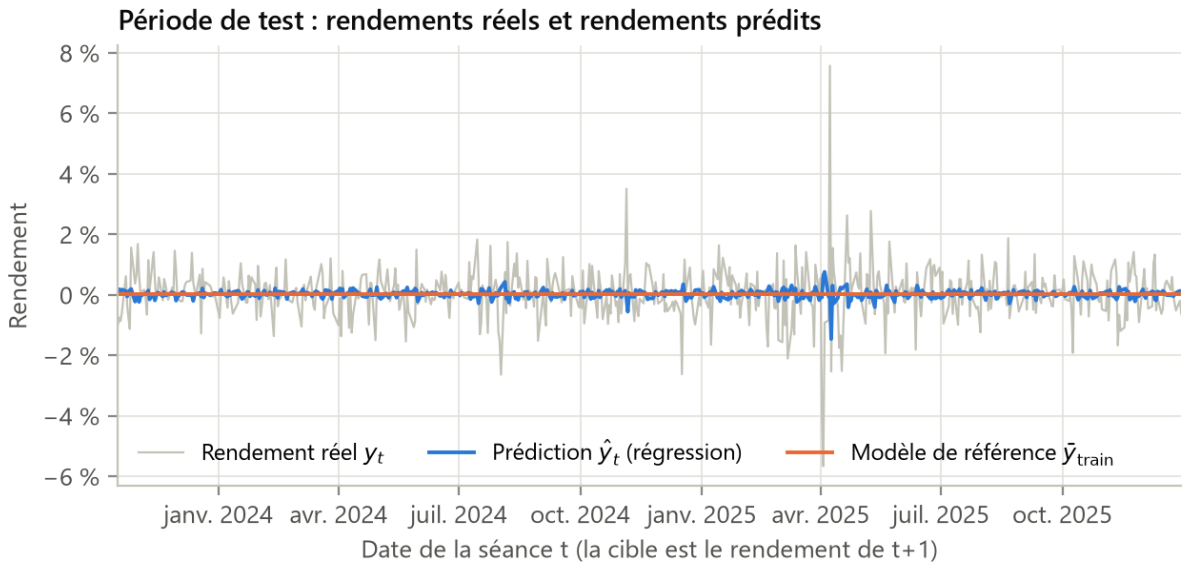


Figure 5 – Période de test : rendements réels (gris), prédictions de la régression (bleu) et moyenne d'entraînement (orange). Les prédictions restent proches de zéro.

par jour, l'ordre de grandeur du rendement moyen.

- $\hat{\beta}_1 = -0{,}15573 < 0$ indique un **retour à la moyenne** à très court terme : une séance à $+1\,\%$ est suivie, en moyenne, d'un rendement inférieur d'environ $0{,}156\,\%$ le lendemain, et inversement. C'est le seul effet statistiquement significatif (tableau 5), mais il est fragile (voir ci-dessous).
- $\hat{\beta}_2 = -0{,}041705 < 0$ suggère qu'une forte amplitude est suivie d'un rendement légèrement plus faible. Cet effet n'est pas significatif ($p = 0{,}15$) : l'amplitude renseigne sur l'*ampleur* des variations futures, pas sur leur *sens*.

Tableau 5 – Significativité des coefficients (entraînement, $n - 3 = 2\,208$ degrés de liberté). É.-t. : écart-type ; robuste : écarts-types de White (HC1).

		Classique			Robuste (HC1)		
Coefficient	Estimation	É.-t.	t	p-valeur	É.-t.	t	p-valeur
β_0	$8{,}183 \cdot 10^{-4}$	$4{,}08 \cdot 10^{-4}$	2,00	0,045	$9{,}99 \cdot 10^{-4}$	0,82	0,41
β_1	−0,1557	0,0214	−7,29	$4 \cdot 10^{-13}$	0,0682	−2,28	0,022
β_2	−0,04170	0,0289	−1,44	0,15	0,0978	−0,43	0,67

Les écarts-types classiques supposent des erreurs de variance constante, ce que dément le regroupement de la volatilité (figure 2). Les écarts-types robustes de White sont environ 3,2 fois plus grands pour β_1 : le t de $\hat{\beta}_1$ passe de $-7{,}29$ à $-2{,}28$ ($p = 0{,}022$), et l'effet reste significatif au seuil de 5 %, mais il est bien moins net qu'il n'y paraît. En fait, il provient entièrement de l'épisode du Covid-19, où les séances de forte baisse et de fort rebond alternaient. Si l'on retire de l'entraînement les 50 séances du 20/02/2020 au 30/04/2020 (2,3 % des observations), on obtient $\hat{\beta}_1 = -0{,}0150$, avec un t robuste de $-0{,}51$: l'effet n'est plus significatif. $\hat{\beta}_2$ change de signe ($+0{,}0452$), $R^2_{\text{train}} = 0{,}16\,\%$ et $R^2_{\text{test}} = -0{,}02\,\% \approx 0$. Sur la période de test, la corrélation entre y et x_1 est d'ailleurs légèrement positive (0,025). Le coefficient $\hat{\beta}_1$ estimé sur tout l'entraînement décrit donc un phénomène propre à une crise, qui ne se reproduit pas pendant la période de test : c'est ce qui explique le R^2 négatif sur le test.

Valeur de R^2. Un R^2 de 2,35 % signifie que les deux variables n'expliquent qu'environ 2 % de la variance du rendement du lendemain, et le R^2 négatif sur le test montre que cette faible part ne se généralise pas. C'est le résultat attendu pour des rendements journaliers d'un grand indice : s'ils étaient prévisibles à partir d'informations publiques aussi simples, les intervenants exploiteraient cette prévisibilité jusqu'à la faire disparaître (hypothèse d'efficience des marchés).

Limites du modèle.

- *Spécification* : modèle linéaire à deux variables ; d'éventuels effets non linéaires (par exemple une dépendance en $|R_t|$) ou d'autres informations (volumes, autres marchés, actualité) sont ignorés.
- *Non-stationnarité* : les relations changent avec le régime de marché (Covid en 2020, période calme et haussière en 2024–2025). Un seul découpage 80/20 ne mesure pas cette instabilité ; une validation glissante serait plus informative.
- *Queues épaisses et valeurs extrêmes* : les résidus sont loin d'être gaussiens (kurtosis en excès 18,5, asymétrie −0,91, figure 6). Le critère quadratique donne un poids considérable à quelques séances extrêmes ; une perte robuste (Huber, valeur absolue) serait moins sensible.
- *Hétéroscédasticité* : l'estimateur des moindres carrés reste sans biais, mais il n'est plus optimal et les tests classiques sont trompeurs (d'où les écarts-types robustes ci-dessus).
- *Critère* : la MSE ne mesure pas l'intérêt économique d'une prévision (sens de variation, coûts de transaction, risque).

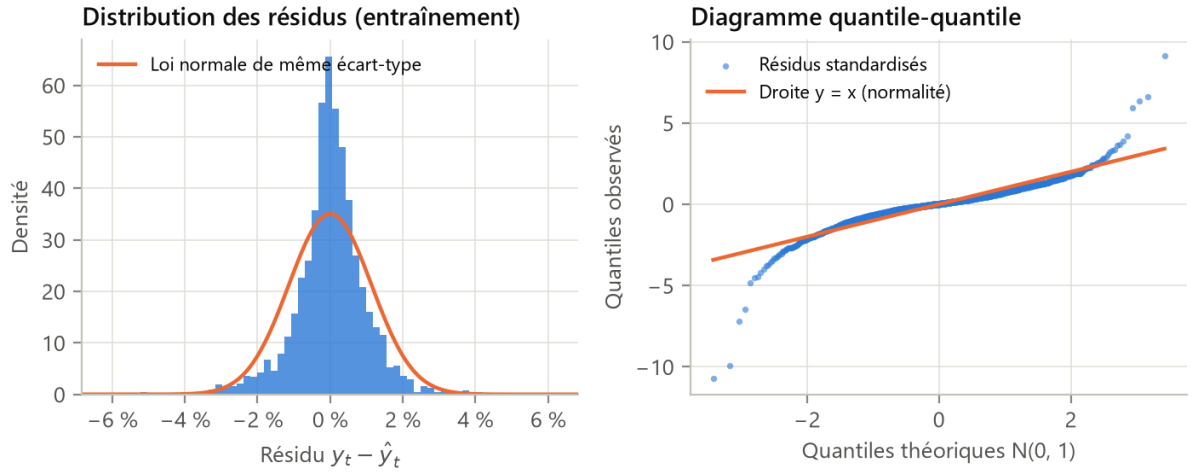


Figure 6 – Résidus d'entraînement : histogramme comparé à une loi normale de même écart-type (à gauche) et diagramme quantile-quantile (à droite). Les points s'écartent de la droite aux extrémités : les queues sont bien plus épaisses que celles d'une loi normale.

3 Partie II : machine à vecteurs de support (SVM)

3.1 Formulation et rappels théoriques

Étiquettes et variables. On pose $z_t = +1$ si $R_{t+1} > 0$ (hausse) et $z_t = -1$ si $R_{t+1} \leq 0$ (baisse). Les variables $x_{1,t}$ et $x_{2,t}$ sont standardisées avec les moyennes et écarts-types de l'entraînement : $\tilde{x}_j = (x_j - m_j)/s_j$, avec $m_1 = 2{,}92 \cdot 10^{-4}$, $s_1 = 1{,}153\,\%$, $m_2 = 1{,}133\,\%$ et $s_2 = 0{,}853\,\%$. Le terme $\frac{1}{2}\|w\|^2$ pénalise toutes les composantes de w de la même façon : sans standardisation, la solution dépendrait des unités des variables. La standardisation améliore aussi le conditionnement (section 2.5).

Problème primal. Avec $x_i = (\tilde{x}_{1,i}, \tilde{x}_{2,i})$ et $f(x) = w^T x + b$, on résout

$$\begin{aligned} (P) \qquad & \min_{w,b,\xi} \ \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{n} \xi_i \\ & \text{sous} \quad z_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, \ldots, n. \end{aligned}$$

Les hyperplans $f(x) = \pm 1$ délimitent une bande de largeur $2/\|w\|$ (la **marge**) : minimiser $\|w\|$ revient à maximiser la marge. La variable d'écart ξ_i mesure la violation de la marge : $0 < \xi_i \leq 1$ pour un point dans la marge mais du bon côté, $\xi_i > 1$ pour un point mal classé. $C > 0$ arbitre entre marge large et violations. À l'optimum $\xi_i = \max(0, 1 - z_i f(x_i))$, donc (P) équivaut à minimiser $\frac{1}{2}\|w\|^2 + C\sum_i \max\big(0, 1 - z_i(w^T x_i + b)\big)$ (perte charnière, ou *hinge loss*). (P) est un problème quadratique convexe à contraintes affines. La condition de Slater est vérifiée (par exemple $w = 0$, $b = 0$, $\xi_i = 2$) : les conditions KKT sont nécessaires et suffisantes, et la dualité forte s'applique.

Lagrangien et dual. Avec des multiplicateurs $\alpha_i \geq 0$ et $\mu_i \geq 0$:

$$\mathcal{L} = \frac{1}{2}\|w\|^2 + C\sum_i \xi_i - \sum_i \alpha_i \big[z_i(w^T x_i + b) - 1 + \xi_i\big] - \sum_i \mu_i \xi_i.$$

L'annulation des dérivées partielles donne $\nabla_w \mathcal{L} = 0 \Rightarrow w = \sum_i \alpha_i z_i x_i$, $\partial_b \mathcal{L} = 0 \Rightarrow \sum_i \alpha_i z_i = 0$ et $\partial_{\xi_i} \mathcal{L} = 0 \Rightarrow \alpha_i + \mu_i = C$, d'où $0 \leq \alpha_i \leq C$. En reportant, on obtient le dual, que résout `SVC` (bibliothèque libsvm, algorithme SMO) :

$$\begin{aligned} (D) \qquad & \max_{\alpha} \ \sum_i \alpha_i - \frac{1}{2}\sum_{i,j} \alpha_i \alpha_j z_i z_j \, x_i^T x_j \\ & \text{sous} \quad 0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i z_i = 0. \end{aligned}$$

Conditions de complémentarité. $\alpha_i \, [z_i f(x_i) - 1 + \xi_i] = 0$ et $(C - \alpha_i)\, \xi_i = 0$. Trois cas se présentent :

- $\alpha_i = 0 \Rightarrow z_i f(x_i) \geq 1$ (point bien classé hors de la marge) ;
- $0 < \alpha_i < C \Rightarrow z_i f(x_i) = 1$ (point sur la marge) ;
- $\alpha_i = C \Rightarrow z_i f(x_i) \leq 1$ (point dans la marge ou mal classé).

Les points tels que $\alpha_i > 0$ sont les **vecteurs supports** : eux seuls déterminent w. Par dualité faible, toute solution réalisable du dual fournit une borne inférieure de la valeur optimale de (P) ; un écart de dualité nul certifie donc l'optimalité.

3.2 Construction et représentation des deux classes

L'entraînement compte 1 187 séances suivies d'une hausse (53,7 %) et 1 024 suivies d'une baisse (46,3 %) ; le test en compte respectivement 305 (55,2 %) et 248 (44,8 %). La figure 7 représente les deux classes dans le plan $(\tilde{x}_1, \tilde{x}_2)$.

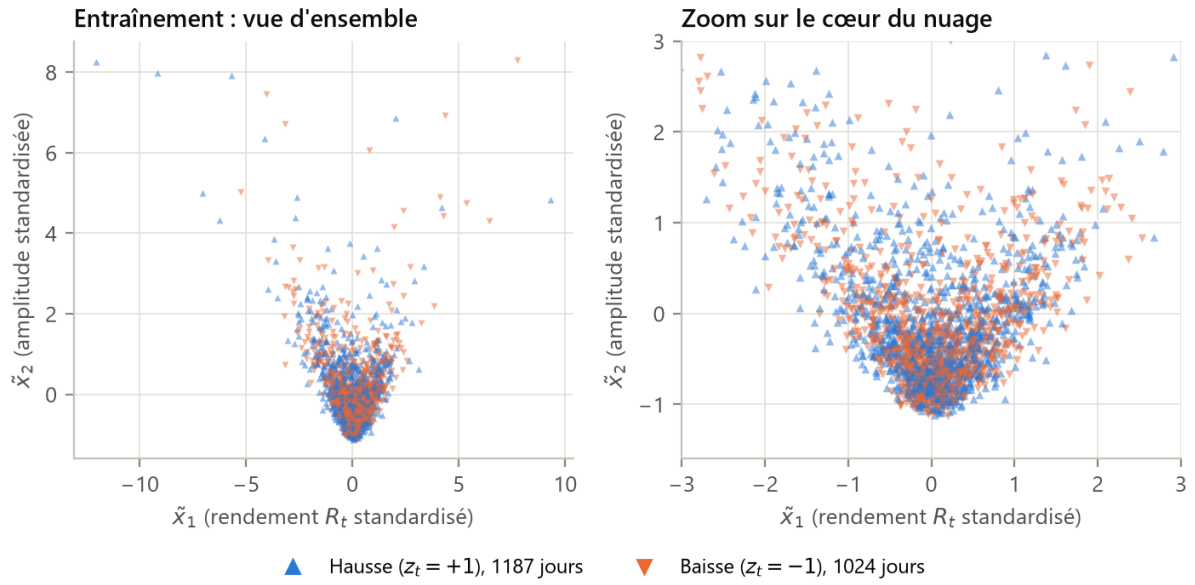


Figure 7 – Classes hausse ($z_t = +1$, triangles bleus) et baisse ($z_t = -1$, triangles orange) dans le plan des variables standardisées, entraînement. Vue d'ensemble (à gauche) et zoom (à droite).

Les deux nuages sont **entièrement superposés**. Leurs barycentres, $(-0{,}042\,;\,0{,}005)$ pour la hausse et $(0{,}049\,;\,-0{,}006)$ pour la baisse, ne sont distants que de 0,092 écart-type. Le nuage a une forme en V : une forte amplitude $\tilde{x}_2$ accompagne les fortes variations $|\tilde{x}_1|$, dans un sens comme dans l'autre. La couleur est mélangée partout : aucune droite ne peut séparer les classes, et le SVM à marge souple (variables ξ_i) est indispensable. On s'attend à de nombreuses erreurs de classification.

3.3 Hyperplan obtenu avec `SVC(kernel='linear')`

Avec $C = 1$, on obtient les paramètres du tableau 6.

Tableau 6 – Paramètres de l'hyperplan obtenu avec `SVC(kernel='linear', C=1)` (variables standardisées).

Grandeur	Valeur	Interprétation
w_1	$2{,}93 \cdot 10^{-5}$	poids du rendement standardisé $\tilde{x}_1$
w_2	$1{,}40 \cdot 10^{-5}$	poids de l'amplitude standardisée $\tilde{x}_2$
b	0,99999	biais (ordonnée de la fonction de décision)
$\|w\|$	$3{,}25 \cdot 10^{-5}$	pratiquement nul
$2/\|w\|$	$6{,}2 \cdot 10^{4}$	largeur de la marge (en écarts-types)
$w^T x_i + b$	$[0{,}99975\,;\,1{,}00033]$	pour tous les points d'entraînement
Vecteurs supports	2 056 sur 2 211	2 041 avec $\alpha_i = C$, 15 avec $0 < \alpha_i < C$
Valeur primale / duale	2048,011 / 2048,000000	écart de dualité relatif $5 \cdot 10^{-6}$

Le résultat est **dégénéré** : $w_1 \approx w_2 \approx 0$ et $b \approx 1$. La fonction de décision $f(x) = w^T x + b$ est pratiquement constante et égale à 1 ; l'hyperplan $f(x) = 0$ se trouve à $|b|/\|w\| \approx 3{,}1 \cdot 10^4$ écarts-types du nuage. Toutes les séances sont classées « hausse », et la précision vaut exactement la proportion de hausses : 53,7 % sur l'entraînement et 55,2 % sur le test. Les valeurs non nulles de w_1, w_2 ne sont que du bruit numérique (la tolérance par défaut de libsvm est 10^{-3}) : avec une tolérance de 10^{-5}, $\|w\|$ tombe à $2{,}0 \cdot 10^{-6}$, et le signe de w change d'une valeur de C à l'autre (tableau 7). Ce n'est pas un échec de l'algorithme : c'est l'optimum exact de (P).

Proposition 1. *Sur les données d'entraînement,* $(w^*, b^*) = (0, 1)$ *est l'unique solution de (P), pour tout* $C > 0$.

Démonstration. Valeur primale. Pour $w = 0$ et $b = 1$, $\xi_i = \max(0, 1 - z_i)$ vaut 0 pour les hausses et 2 pour les baisses ; la valeur de (P) est donc $2Cn_-$, soit 2 048 pour $C = 1$ et $n_- = 1\,024$.

Certificat dual. Posons $\alpha_i = C$ pour chaque baisse et $\alpha_i = Cn_-\lambda_i$ pour chaque hausse, où les poids $\lambda_i \in [0, 1/n_-]$, de somme 1, vérifient $\sum_{i:z_i=+1} \lambda_i x_i = \bar{x}_-$, le barycentre des baisses. Alors $0 \le \alpha_i \le C$, $\sum_i \alpha_i z_i = Cn_- - Cn_- = 0$ et $\sum_i \alpha_i z_i x_i = Cn_-\big(\sum_+ \lambda_i x_i - \bar{x}_-\big) = 0$. La valeur duale vaut donc $\sum_i \alpha_i = 2Cn_-$, égale à la valeur primale : par dualité faible, $(0, 1)$ est optimal.

Unicité. Le terme $\frac{1}{2}\|w\|^2$ étant strictement convexe, tous les optimums ont le même $w^* = 0$. Pour $w = 0$, le coût $C\,[n_+ \max(0, 1 - b) + n_- \max(0, 1 + b)]$ est minimal uniquement en $b = 1$, car $n_+ > n_-$.

Vérification numérique. L'existence des λ_i est un problème de programmation linéaire, résolu avec succès : le barycentre des baisses appartient à l'« enveloppe convexe réduite » des hausses, avec un poids maximal minimal de $8{,}95 \cdot 10^{-4} < 1/n_- = 9{,}77 \cdot 10^{-4}$. La valeur duale calculée par libsvm, 2048,000000, est bien égale à $2Cn_-$. Le raisonnement ne dépend pas de C (les α_i sont proportionnels à C) : pour tout $C > 0$, le SVM linéaire prédit « hausse » partout, comme le confirme le tableau 7. □

Autrement dit, les classes sont tellement imbriquées qu'aucune direction w ne réduit assez la somme des pertes charnières pour compenser le coût $\frac{1}{2}\|w\|^2$. La meilleure décision est alors de placer tous les points du côté de la classe majoritaire. Les conditions KKT sont vérifiées par la solution numérique : 2 041 points ont $\alpha_i = C$ (dont les 1 024 baisses, toutes mal classées), $w = \sum_i \alpha_i z_i x_i$ à 0 près, et l'écart de dualité relatif est de $5 \cdot 10^{-6}$.

Tableau 7 – SVM linéaire (sans pondération) pour différentes valeurs de C.

C	w_1	w_2	b	$\|w\|$	Vect. supp.	Préc. entr.	Préc. test	Prédit hausse
0,001	$2{,}0 \cdot 10^{-5}$	$-3{,}9 \cdot 10^{-5}$	1,00005	$4{,}4 \cdot 10^{-5}$	2 049	53,7 %	55,2 %	100 %
0,01	$1{,}5 \cdot 10^{-6}$	$7{,}4 \cdot 10^{-7}$	1,00000	$1{,}6 \cdot 10^{-6}$	2 050	53,7 %	55,2 %	100 %
0,1	$-2{,}1 \cdot 10^{-6}$	$2{,}9 \cdot 10^{-7}$	1,00000	$2{,}1 \cdot 10^{-6}$	2 051	53,7 %	55,2 %	100 %
1	$2{,}9 \cdot 10^{-5}$	$1{,}4 \cdot 10^{-5}$	0,99999	$3{,}3 \cdot 10^{-5}$	2 056	53,7 %	55,2 %	100 %
10	$-1{,}0 \cdot 10^{-5}$	$9{,}5 \cdot 10^{-6}$	0,99999	$1{,}4 \cdot 10^{-5}$	2 080	53,7 %	55,2 %	100 %
100	$-5{,}7 \cdot 10^{-5}$	$-4{,}9 \cdot 10^{-5}$	0,99996	$7{,}5 \cdot 10^{-5}$	2 095	53,7 %	55,2 %	100 %

3.4 Représentation graphique, régions de classification et erreurs

La figure 8 représente la solution $C = 1$: tout le plan est la région « hausse » et l'hyperplan est hors de la figure. Pour obtenir un hyperplan visible et discuter une séparation non triviale, nous avons aussi entraîné le SVM avec des **poids de classes équilibrés** (`class_weight='balanced'`, $C_i = C \cdot \frac{n}{2n_{z_i}}$, soit 0,9313 pour les hausses et 1,0796 pour les baisses). La solution triviale coûte alors autant pour tout $b \in [-1, 1]$ et n'est plus optimale. On obtient

$$w = (-0{,}3153\,;\, 0{,}0994), \qquad b = -0{,}3123,$$
$$\text{hyperplan :} \quad -0{,}3153\,\tilde{x}_1 + 0{,}0994\,\tilde{x}_2 - 0{,}3123 = 0 \iff \tilde{x}_2 = 3{,}14 + 3{,}17\,\tilde{x}_1,$$

soit, dans les unités d'origine, $-27{,}34\,x_1 + 11{,}65\,x_2 - 0{,}4363 = 0$. La marge $2/\|w\| = 6{,}05$ couvre presque tout le nuage : 2 193 points sur 2 211 sont vecteurs supports, 1 041 sont dans la marge en étant bien classés, et 1 151 sont mal classés (écart de dualité relatif $2 \cdot 10^{-7}$). La figure 9 montre l'hyperplan, les deux marges et les deux régions.

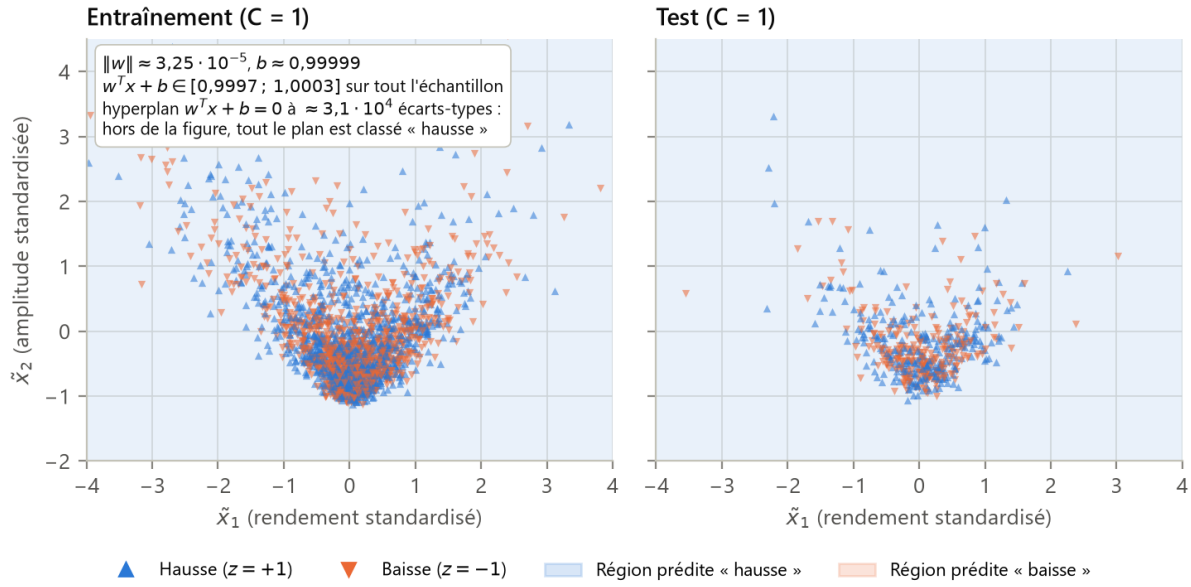


Figure 8 – SVM linéaire, $C = 1$: la fonction de décision vaut pratiquement 1 partout, si bien que tout le plan est la région « hausse » ; l'hyperplan $w^T x + b = 0$ est situé à environ $3{,}1 \cdot 10^4$ écarts-types, hors de la figure.

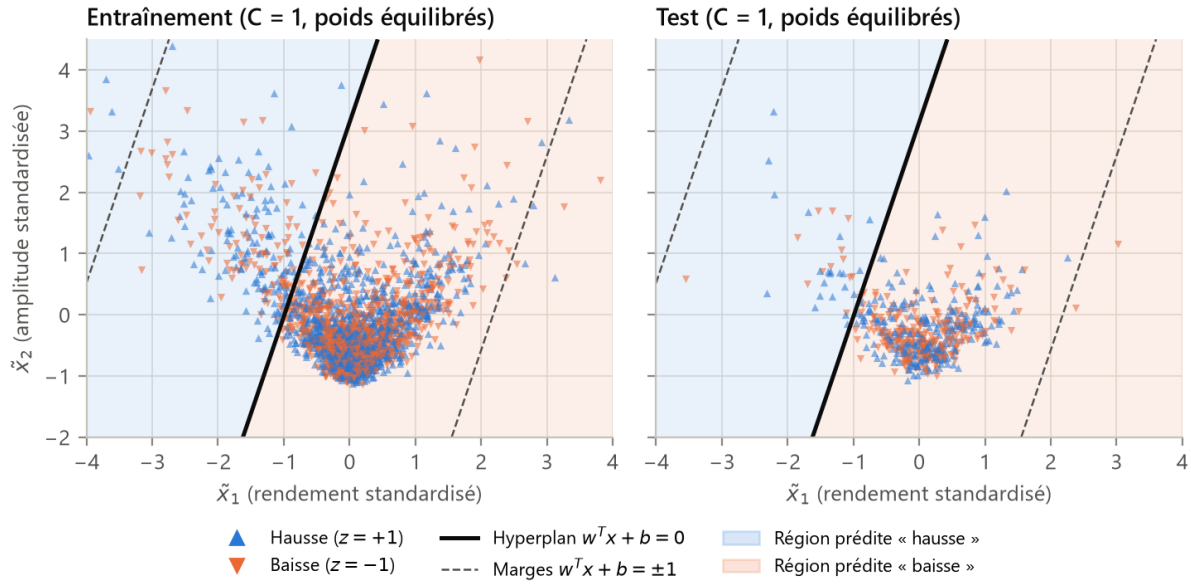


Figure 9 – SVM linéaire, $C = 1$, poids de classes équilibrés : hyperplan (trait plein), marges $w^T x + b = \pm 1$ (tirets) et régions de classification, sur l'entraînement (à gauche) et sur le test (à droite).

Interprétation de la séparation. La région « hausse » ($f > 0$) est la zone en haut à gauche : séances de forte baisse ($\tilde{x}_1$ négatif) et/ou de forte amplitude, après lesquelles le modèle anticipe un rebond. On retrouve le signe négatif de $\hat{\beta}_1$ de la partie I (retour à la moyenne), avec la même fragilité, puisque ces points datent surtout de 2020. Le cœur du nuage, formé des séances calmes, est classé « baisse » : le SVM pondéré ne prédit une hausse que pour 11,0 % des séances d'entraînement et 7,1 % des séances de test.

Tableau 8 – Matrices de confusion ($C = 1$; « SVM pondéré » : poids de classes équilibrés). Les cases « réel hausse, prédit baisse » et « réel baisse, prédit hausse » sont les erreurs de classification.

		Réel hausse		Réel baisse		
Modèle	Ensemble	prédit hausse	prédit baisse	prédit hausse	prédit baisse	Précision
SVM	Entraînement	1 187	0	1 024	0	53,7 %
SVM	Test	305	0	248	0	55,2 %
SVM pondéré	Entraînement	140	1 047	104	920	47,9 %
SVM pondéré	Test	23	282	16	232	46,1 %

Erreurs de classification. Le tableau 8 donne les matrices de confusion.

- Avec $C = 1$, toutes les baisses sont mal classées et toutes les hausses bien classées.
- Avec des poids équilibrés, les erreurs se répartissent entre les deux classes : la plupart des hausses tombent dans la région « baisse ». La précision tombe à 47,9 % sur l'entraînement et 46,1 % sur le test, et la précision équilibrée (moyenne des taux de bonnes réponses par classe) vaut 50,8 % et 50,5 %, ce qui est indiscernable du hasard (50 %).

Ces erreurs ne viennent ni de l'algorithme ni du choix de C. La loi de $(\tilde{x}_1, \tilde{x}_2)$ est pratiquement la même pour les deux classes (figure 7), donc la probabilité d'une hausse est à peu près la même, $\approx 53{,}7\,\%$, en tout point du plan. Dans ces conditions, on ne peut guère espérer qu'une autre frontière, même non linéaire, fasse nettement mieux que la règle « toujours hausse ». Un essai complémentaire le confirme sur le test : le SVM à noyau RBF classe correctement 55,2 % des séances (il prédit « hausse » dans 99 % des cas), sa version à poids équilibrés 48,5 %, la méthode des 51 plus proches voisins 49,0 % et la régression logistique 55,5 %, avec des précisions équilibrées comprises entre 47,4 % et 51,5 %, contre 55,2 % pour « toujours hausse ». Enfin, 21 points d'entraînement (dont 15 de mars 2020) et 4 points de test (du 04/04/2025 au 09/04/2025, choc des droits de douane) sortent de la fenêtre des figures 8 et 9 ; ils sont classés selon le prolongement des régions représentées.

Discussion. Le SVM optimise la perte charnière et non la précision. Quand les classes se recouvrent, la notion de marge perd son sens géométrique (marge immense, presque tous les points sont vecteurs supports), et la solution dépend surtout du déséquilibre entre les classes. Des pistes d'amélioration seraient d'autres variables (rendements sur plusieurs jours, volumes, indices de volatilité), un noyau non linéaire (section 4), un modèle probabiliste (régression logistique) avec un seuil ajusté, et une validation glissante. Toutefois, le sens de variation journalier d'un grand indice reste proche d'un tirage à pile ou face.

4 Travaux futurs : l'astuce du noyau

Le SVM linéaire ne peut tracer qu'une droite dans le plan $(\tilde{x}_1, \tilde{x}_2)$. Or le nuage a une forme en V (figure 7) : une éventuelle information porterait sur $|\tilde{x}_1|$ ou sur $\tilde{x}_1^2$, qu'aucune frontière linéaire en $(\tilde{x}_1, \tilde{x}_2)$ ne peut exploiter. L'astuce du noyau permet de chercher une frontière non linéaire sans changer la nature du problème d'optimisation.

4.1 Principe

On envoie les points dans un espace de plus grande dimension par une application $\varphi : \mathbb{R}^2 \to \mathcal{H}$, et on y cherche un hyperplan. Dans le dual (D), les données n'interviennent que par les produits scalaires $x_i^T x_j$. Il suffit donc de remplacer $x_i^T x_j$ par un noyau $K(x_i, x_j) = \varphi(x_i)^T \varphi(x_j)$, sans jamais calculer φ :

$$(D_K) \qquad \max_{\alpha} \ \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j z_i z_j \, K(x_i, x_j)$$
$$\text{sous} \quad 0 \le \alpha_i \le C, \quad \sum_i \alpha_i z_i = 0.$$

La fonction de décision devient

$$f(x) = \sum_i \alpha_i z_i \, K(x_i, x) + b,$$

où $b = z_k - \sum_i \alpha_i z_i \, K(x_i, x_k)$ pour un indice k tel que $0 < \alpha_k < C$ (point situé sur la marge). Si la matrice de Gram $\big(K(x_i, x_j)\big)_{i,j}$ est semi-définie positive (condition de Mercer), (D_K) reste un problème quadratique convexe : les conditions KKT, la dualité forte et l'algorithme SMO de la partie II s'appliquent sans changement.

Noyaux envisagés.

- *Polynomial de degré 2* : $K(x, x') = (x^T x' + 1)^2$, qui correspond à $\varphi(x) = (1, \sqrt{2}\,x_1, \sqrt{2}\,x_2, x_1^2, \sqrt{2}\,x_1 x_2, x_2^2)$. La frontière $f(x) = 0$ est alors une conique du plan, capable de suivre la forme en V du nuage.
- *Gaussien (RBF)* : $K(x, x') = \exp\big(-\gamma \|x - x'\|^2\big)$, qui correspond à un espace $\mathcal{H}$ de dimension infinie. Le paramètre γ règle la portée de chaque point : un grand γ donne une frontière très locale et un risque de sur-apprentissage.

Extension à la régression. L'astuce s'applique aussi à la partie I. Avec une pénalisation $\frac{\lambda}{2}\|\beta\|^2$, indispensable dès que $\mathcal{H}$ est de grande dimension, le minimiseur de $\frac{1}{2n}\|\Phi\beta - y\|^2 + \frac{\lambda}{2}\|\beta\|^2$ (cible centrée) s'écrit $\beta = \Phi^T a$, avec

$$(K + n\lambda I)\, a = y, \qquad \hat{y}(x) = \sum_i a_i \, K(x_i, x),$$

où Φ est la matrice dont les lignes sont les $\varphi(x_i)^T$ et $K = \Phi\Phi^T$ la matrice de Gram (*kernel ridge regression*). C'est l'analogue de l'équation normale (4), écrit dans l'espace des observations ($n \times n$) au lieu de l'espace des paramètres.

4.2 Protocole prévu

- Choisir C et γ (ou le degré du noyau) par validation croisée *chronologique* sur l'entraînement uniquement (blocs successifs, sans mélange), pour respecter l'ordre du temps comme dans la section 1.3.
- Évaluer sur le test avec la précision équilibrée et l'aire sous la courbe ROC, et comparer à la règle « toujours hausse » (55,2 %) et au SVM linéaire.
- Enrichir les variables : rendements sur plusieurs jours, volumes, volatilité implicite (VIX). Un noyau ne crée pas d'information : il ne peut exploiter qu'une dépendance non linéaire déjà présente dans les variables.
- Surveiller le coût : la matrice de Gram compte $n^2 \approx 4{,}9 \cdot 10^6$ coefficients, ce qui reste raisonnable ici. Pour des données plus longues (par exemple intrajournalières), des approximations comme la méthode de Nyström ou les *random Fourier features* seraient nécessaires.

Un premier essai avec un noyau RBF (section 3.4) donne 55,2 % de précision sur le test, mais en prédisant « hausse » dans 99 % des cas. Avec les deux variables actuelles, le gain attendu est donc faible ; l'intérêt de l'astuce du noyau dépendra surtout des nouvelles variables.

5 Conclusion

Ce projet a appliqué deux problèmes d'optimisation convexe aux rendements quotidiens du Dow Jones.

- **Régression linéaire.** La fonction J est quadratique et convexe, de hessienne constante $\frac{1}{n}X^TX$ définie positive. Son unique minimiseur est caractérisé par l'équation normale $X^TX\hat{\beta} = X^Ty$, qui donne $\hat{\beta} = (8{,}18 \cdot 10^{-4}\,;\, -0{,}156\,;\, -0{,}0417)$. Toutes les méthodes numériques retrouvent cette solution ; leur vitesse dépend du conditionnement κ, que la standardisation fait passer de $1{,}47 \cdot 10^4$ à 1,44. Le modèle n'explique que 2,35 % de la variance sur l'entraînement et $R^2 = -3{,}69\,\%$ sur le test. Le seul effet notable, un léger retour à la moyenne ($\hat{\beta}_1 < 0$), disparaît quand on retire les 50 séances de l'épisode du Covid-19.
- **SVM linéaire.** Le problème (P) a pour solution exacte $w = 0$, $b = 1$, ce que prouve un certificat dual vérifié par programmation linéaire : les classes hausse et baisse sont imbriquées au point qu'aucun hyperplan ne les sépare mieux que la règle « toujours hausse » (précision 55,2 % sur le test). Avec des poids équilibrés, l'hyperplan devient visible et cohérent avec le retour à la moyenne, mais sa précision équilibrée reste celle du hasard.

Les deux approches conduisent à la même conclusion, conforme à l'hypothèse d'efficience des marchés : le rendement et le sens de variation du lendemain sont presque imprévisibles à partir du rendement et de l'amplitude du jour. La suite naturelle de ce travail est l'astuce du noyau (section 4), associée à de nouvelles variables explicatives.

Calculs réalisés avec Python 3.11 (NumPy, SciPy, scikit-learn, pandas, Matplotlib).
Code source, données et figures : `https://github.com/SalemEssid/Optimization_project.git`